




基于生成式LLM和混淆集增强的 中文拼写纠错模型构建 课程大作业开题报告

汇报人：张斐枫 组员：薛婷妤

2026年4月27日

01 项目背景与意义

什么是中文拼写纠错 (CSC)?

NLP领域的基础任务，旨在自动检测并纠正文本中的拼写错误。常见错误源于**音近字**混淆（如“香蕉”→“相交”）和**形近字**混淆（如“自己”→“自已”）。

核心应用场景

输入法：实时修正打字错误

搜索引擎：精准理解用户的错误意图

OCR处理：修正扫描/拍照识别错误

内容审核：提升UGC内容质量与可读性

教育批改：帮助教师审核作业内容

中文拼写纠错具有明确的NLP研究价值。

为什么选择该方向？

技术主流：LLM生成式任务与纠错本质高度契合

课程匹配：可以从零构建Decoder核心组件，深入理解Transformer

研究价值：引入混淆集先验知识，具备实践意义

02 任务定义

Chinese Spelling Correction Model shibing624/macbert4csc-base-chinese

Copy or input error Chinese text. Submit and the machine will correct text.

text **输入（错误句子）**

真麻烦你了。希望你们好好的跳无

Clear

Submit

output **输出（修正后的句子）**

真麻烦你了。希望你们好好地跳舞 [('的', '地', 12, 13), ('无', '舞', 14, 15)]

形式化建模

输入序列: $X = (x_1, x_2, \dots, x_n)$

输出序列: $Y = (y_1, y_2, \dots, y_n)$

任务目标

条件概率生成

$$P(Y|X) = \prod P(y_i|y_{<i}, X)$$


03 技术方案与模型架构



整体技术路线：数据准备→模型构建→预训练与后训练→微调与评估

● 核心模型搭建：基于Decoder-Only

- **Tokenizer**: 使用开源的BPE词表
- **Causal-Self-Attention & FFN**: 使用因果注意力捕捉上下文关联；使用前馈网络实现非线性变换。
- **Layer Normalization**: 通过标准化层间输出来稳定训练并显著加速收敛。
- **自回归生成头**: 最后一层隐状态经线性变换映射到词表维度，并通过 Softmax 得到下一个 token 的概率分布。



01 / 预训练

在大规模构造的错误数据上进行因果语言模型任务训练，使模型学习基础语言规律与初步的错字识别能力。



02 / 后训练

引入专业CSC数据集进行监督微调，将通用模型能力迁移并适配到中文纠错的具体场景中。



03 / 评估

综合使用检测与纠正任务的两套 P/R/F1 标准指标，全方位量化模型的纠错性能。

04 项目创新点：混淆集增强方法

本项目的核心创新在于将 音近 / 形近混淆集 作为先验知识引入模型训练过程，针对性地强化模型对高频易错字的识别与纠错能力。

辨析字组音序索引

A		àn		bá	
		暗 黯	3	拔 跋 拔	7
āi		àng		bǎ	
	1	盍 盍	4	靶 靶	8
ái		áo		bān	
	1	遨 遨	6	斑 斑	8
ǎi		ào		bān	
	4	颞 颞	4	颁 颁	9
ǎi		ào		bǎn	
	2	藁 藁	5	板 版	9
ǎi		ào		bàn	
	2	藁 藁	5	伴 拌 拌	10
ǎn		B		bāng	
	3	芭 芭	7	帮 帮	10
ǎn		bā			
	3	芭 芭	7	柳 柳	12

音近混淆集

构建方法：可以利用 `pypinyin`库提取拼音，将同音字自动聚类分组。
核心作用：提升模型对“同音异形”错误的语境辨别能力。
典型示例：[的 / 得 / 地]、[进 / 近]、[以 / 已]、[再 / 在]

形近字 I

mù yáng (牛羊)	yuán yuán qì 元 (元气)	lái lái wǎng 来 (来往)	mù mù 木 (木)
zhōng wú (中午)	wú wú fǎ 无 (无法)	lái lái shǒu 类 (类手)	tān shū 本 (书)
tǔ dì (土地)	hòu hòu lái 后 (后来)	zài zài zài 在 (自在)	míng míng 明 (明)
tā men (他们)	shí shí tóu 石 (石头)	zuǒ zuǒ zuǒ 左 (左边)	píng píng 朋 (朋)
yún duǎn (云彩)	kāi kāi shǐ 开 (开始)	jǐ jǐ jǐ 己 (自己)	xiǎo xiǎo 鸟 (小)
qù nián (去年)	shàng shàng qǐ 升 (升起)	yǐ yǐ yǐ 已 (已经)	wū wū 乌 (乌)
shàng qǐ (丢弄)	pǐng pǐng pǐng 井 (水井)	yí yí yí 已 (已时)	mǎ mǎ 马 (白)
quán jiā (全家)	zǎo zǎo chen 早 (早晨)	wèn wèn wèn 问 (询问)	yǎ yǎ 牙 (牙)
jīn zǐ (金子)	zǎo zǎo zǎo 早 (干旱)	jiàn jiàn jiàn 间 (房间)	yá yá 芽 (发)
cǐ cǐ (尺子)	cóng cóng cóng 丛 (丛林)	mǎ mǎ mǎ 妈 (妈妈)	wǒ wǒ 我 (我)
yǐ yǐ (尸体)	cóng cóng cóng 丛 (丛林)	mǎ mǎ mǎ 妈 (妈妈)	zhǎo zhǎo 找 (寻)

形近混淆集

构建方法：可以参考 `Homoglyph` 思路，计算汉字的同形距离进行分组。
核心作用：增强模型对“形异义近”错误的视觉捕捉与语义区分能力。
典型示例：[人 / 入]、[今 / 令]、[晴 / 睛]、[酒 / 洒]

预期效果：通过在训练阶段针对性引入混淆集，引导模型学习汉字间的细微差别，显著降低因发音或字形相似而导致的识别错误率

04 项目创新点：混淆集增强

本项目的核心创新在于将 音近 / 形近混淆集 作为先验知识引入模型训练过程，针对性地强化模型对高频易错字的识别与纠错能力。

混淆集引入到模型训练策略

策略1：在预训练/微调阶段，提高混淆字被选中的概率（而非均匀采样词汇表）

策略2：构造训练样本时，错误位置优先使用混淆集中的字进行替换

策略3：在损失函数中加入混淆字区分辅助损失（如有混淆集内的字出现，加大惩罚权重）

策略4：在推理阶段，预测时候选集缩小到混淆集

核心方法：

1.数据层：利用混淆集构造错误样本，数据格式为自回归生成对


2.训练层：在自回归交叉熵损失上实施逐 token 加权，并结合 LoRA 进行高效微调。

3.预测层：在自回归生成每一步，利用混淆集实施受限解码，并结合可选的外部检索增强 (RAG) 上下文。

05 数据与模型资源


丰富的数据集支持

- **MD-CSC:**多领域中文拼写纠错数据集，覆盖法律、医疗等垂直领域，数据真实度高。
- **SIGHAN 2015:**公认的中文拼写纠错领域标准评测数据集，用于模型基准测试。
- **社区开源:**shibing624/chinese_text_correction 覆盖社交媒体、新闻等多种真实场景。
- **CTCResources:**哈工大讯飞联合实验室整理的中文文本纠错领域全资源汇总。



工具与参考模型

- **对比模型:**哈工大讯飞发布的 Chinese-BERT-wwm 中文预训练模型，保证语言理解能力。
- **纠错工具:**pycorrector，集成多种主流纠错算法，提供完整的评估体系与基础数据支持。
- **混淆集构建:**利用 imewlconverter 提取输入法同音混淆对，结合 HomoglyphsCJK 构建形近字混淆集。
- **资源平台:**所有代码、模型与数据集均开源在 GitHub 和 Hugging Face。



06 实验设计（仅改变混淆集相关模块，其余设置保持一致）

实验设置

Baseline

模型	方法说明
BERT	无混淆集，仅MLM
pycorrector	规则 + 统计方法

我们的模型

LLM + 混淆集

- 1.数据增强（错误注入）
- 2.候选约束（限制预测空间）

对比实验

不同错误类型分析

错误类型	示例
音近字	在 / 再
形近字	未 / 末

不同增强策略对比

模型	组件
A	数据增强
B	数据增强+RAG
C	完整模型

07 进度安排与预期成果

技术路线与时间规划

01 数据准备

收集中文语料，构建高质量的音近/形近混淆集。

02 模型构建

从零实现核心组件，搭建基础纠错网络架构。

03 预训练

在人工构造的错误数据上，进行模型预训练。

04 微调与评估

在CSC公开数据集上进行模型微调，并完成基础性能评测。

05 实验对比

进行混淆集增强前后的消融实验，量化分析方法有效性。

06 报告撰写

整理实验结果，完成最终的研究报告与答辩演示PPT。

预期成果



轻量级纠错模型

实现一个可运行的中文拼写纠错模型，且代码具备可扩展性。



标准评测结果

在SIGHAN等权威数据集上提交模型，并产出精确率、召回率和F1指标。



混淆集构建方案

沉淀一套高效的音近/形近混淆集构建方法，以及配套的开源代码工具。



对比分析报告

撰写详细的实验对比分析报告，论证混淆集增强技术的有效性与价值。

THANKS

本项目主要研究 “LLM+ 先验知识融合”
的中文拼写纠错方法

